


2025

Grupo 1B

Projeto

 linqi





Agenda



● Descrição do Problema

● Estrutura dos dados

● Análise exploratória

● Modelos

● Resultados

● Conclusão

Desafio



Dona Sara
(cliente exigente)



Prescrever para os próximos
7 dias a quantidade que cada
loja deve ter de cada produto
(SKU – Stock Keeping Unit).

DESCRIÇÃO DO PROBLEMA

Predizer a quantidade ideal de SKUs (*Stock Keeping Units*)

Permite otimizar recursos e reduzir perdas

Passos:

- Entender os dados
- Identificar as variáveis que influenciam nas vendas
- Construir modelos de predição
- **Premissa:** não pode faltar nem sobrar



Estrutura dos Dados

- Vendas realizadas por diferentes lojas no **período de 2022 ao início de 2025**.
- Na base de dados recebida estão presentes **41.389.576 registros**.
- Há **10 variáveis** na base de dados.

ID da loja

10 no total

ID do produto

5290 no total

ID da categoria

11 no total

Flag medicamento

53,8% é
medicamento

Curva ABCDE

Data

Estoque

Venda

Custo

Preço




Variáveis adicionais


- Foram criadas variáveis adicionais.
- **Objetivo:** capturar cada um dos efeitos de sazonalidade de forma individual e complementar.

Mês

Dia da semana


Semana do mês










Tendência de Vendas e Estoque ao Longo do Tempo











Definição Treino e Teste



Corrigindo os erros das análises preliminares, definimos o conjunto de **Treino** como os dias correspondentes aos primeiros 80% da amostra e o conjunto de **Teste** como os 20% restantes



Depois dos parâmetros definidos, o melhor modelo foi treinado em 100% dos dados para validação com os **7** dias adicionais



Modelos



✦ Modelos testados

- *Linear Regression*
- *Decision Tree*
- *Random Forest*
- *Gradient Boosting*
- *XGBoost*
- *LightGBM*

✦ Medidas de desempenho

A verificação de desempenho dos modelos será feita por meio do **MAE** e **SMAPE**.



$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$SMAPE = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|) / 2} \times 100$$

Projeto Linqi

Resultados Modelos Iniciais

p/ loja 1



MODELO	MSE	RMSE	R ²	MAE	SMAPE
Linear Regression	0.455089	0.674603	0.36601	0.211103	194.777
Decision Tree	0.8292	0.910604	-0.155169	0.1965	21.576
Random Forest	0.398246	0.631067	0.445198	0.177049	126.571
Gradient Boosting	0.429631	0.655462	0.401475	0.18492	194.999
XGBoost	0.393171	0.627034	0.452268	0.177475	194.817



Na primeira semana:




Usar modelos de
regressão para
prever estoque

Leakage!



Depois de 4 meses:



Modelos

Mudanças em relação à apresentação anterior:

- Remoção da variável **Estoque** das variáveis explicativas
- Transformação da variável resposta de volta para a escala original para cálculo correto das métricas de desempenho
- Melhor definição dos conjuntos de treino e teste para eliminar o *leakage*




Resultado

**Piora no desempenho
de todos os modelos**

Modelos

✦ Mudança do modelo escolhido :

*Random
Forest*




*Light
GBM*



Após os ajustes na metodologia, os modelos foram reavaliados em uma amostra piloto, e desta vez o **LightGBM** teve melhor desempenho, além de um tempo de execução menor.

45 min por amostra
lojaN_curvaX




20 min por amostra
lojaN_curvaX


✦ *LightGBM*

- Expande somente a folha que gera o maior ganho de informação
- Árvores mais profundas em alguns ramos
- O objetivo é reduzir o erro mais rapidamente

Nível por Nível





Nível com mais informação





LightGBM

Implementação do Modelo



Resultados Modelo Final (s/ estoque)



Loja	Curva	MAE	SMAPE (%)	Loja	Curva	MAE	SMAPE (%)
Loja 1	A	1,003	58,3	Loja 6	A	0,934	57,3
	B	0,326	37,6		B	0,271	33,3
	C	0,096	15,0		C	0,079	12,0
	D	0,023	3,7		D	0,020	3,1
Loja 2	A	1,143	50,1	Loja 7	A	0,586	40,6
	B	0,311	34,5		B	0,142	18,6
	C	0,088	13,1		C	0,047	7,4
	D	0,022	3,5		D	0,021	3,1
Loja 3	A	0,714	50,9	Loja 8	A	0,706	54,9
	B	0,214	27,6		B	0,216	28,2
	C	0,060	10,0		C	0,068	10,8
	D	0,016	2,8		D	0,018	2,8
Loja 4	A	0,612	44,1	Loja 9	A	0,514	34,8
	B	0,161	22,2		B	0,114	14,9
	C	0,047	7,7		C	0,039	6,0
	D	0,017	2,7		D	0,017	2,4
Loja 5	A	1,019	52,7	Loja 10	A	1,034	55,1
	B	0,254	32,5		B	0,266	30,7
	C	0,074	11,9		C	0,070	10,8
	D	0,020	3,3		D	0,018	2,9

Média por Curva

Curva	MAE	SMAPE
A	0,827	49,873
B	0,227	28,000
C	0,067	10,456
D	0,019	3,021

VAR por Curva

Curva	MAE	SMAPE
A	0,050	59,372
B	0,005	53,945
C	0,000	7,679
D	0,000	0,156

Projeto Linqi



Dona Sara



Resultados da previsão de 7 dias







Resultados Validação 7 Dias

Loja	Curva	MAE	SMAPE (%)	Loja	Curva	MAE	SMAPE (%)
Loja 1	A	1,080	66,0	Loja 6	A	0,847	53,5
	B	0,348	40,2		B	0,281	33,6
	C	0,086	13,6		C	0,070	10,9
	D	0,018	3,1		D	0,024	2,5
Loja 2	A	1,589	51,1	Loja 7	A	0,697	45,7
	B	0,295	34,5		B	0,137	17,2
	C	0,076	12,1		C	0,037	6,0
	D	0,021	2,9		D	0,012	2,0
Loja 3	A	0,870	54,0	Loja 8	A	0,797	62,7
	B	0,207	27,9		B	0,224	29,2
	C	0,053	8,9		C	0,060	10,0
	D	0,014	2,3		D	0,018	3,0
Loja 4	A	0,621	46,1	Loja 9	A	0,551	36,9
	B	0,151	20,5		B	0,110	15,0
	C	0,045	7,1		C	0,039	5,8
	D	0,013	2,0		D	0,017	2,5
Loja 5	A	1,194	52,5	Loja 10	A	1,230	57,3
	B	0,241	30,9		B	0,275	31,5
	C	0,069	11,0		C	0,064	10,2
	D	0,017	2,5		D	0,017	2,6

Média por Curva		
Curva	MAE	SMAPE
A	0,948	52,574
B	0,227	28,046
C	0,060	9,565
D	0,017	2,517

VAR por Curva		
Curva	MAE	SMAPE
A	0,104	71,806
B	0,006	64,878
C	0,000	6,762
D	0,000	0,138

Resultados Validação 7 Dias



Resultados Validação 7 Dias



Top 3 melhores resultados

MAE:

loja 7 curva D (0,0123)

loja 4 curva D (0,0132)

loja 3 curva D (0,0139)

SMAPE:

loja 7 curva D (1,95%)

loja 4 curva D (1,99%)

loja 5 curva D (2,54%)



Top 3 piores resultados

MAE:

loja 2 curva A (1,589)

loja 10 curva A (1,230)

loja 5 curva A (1,194)

SMAPE:

loja 1 curva A (66,04%)

loja 10 curva A (57,27%)


loja 3 curva A (53,98%)

Projeto Linqi



Conclusão

Desenvolvemos modelos de *Machine Learning* para prever níveis de estoque com base em dados históricos de vendas.



Principais resultados:

- Modelo com melhor desempenho: ***LightGBM***.
- Métricas: *MAE* e *SMAPE*.
- Capacidade razoável de prever demanda futura, porém muito incerto.



Limitações:

- Grande quantidade de dados → Limitação computacional
- Fatores externos não incluídos → ex.: promoções



CHEN, T.; GUESTRIN, C. Xgboost: A scalable tree boosting system. In: PROCEEDINGS of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. [S.l.: s.n.], 2016. P. 785–794.

CHU, W.; ZHANG, C.; LI, H.; ZHANG, L.; SHEN, D.; LI, R. SHAP-powered insights into spatiotemporal effects: Unlocking explainable Bayesian-neural-network urban flood forecasting. **International Journal of Applied Earth Observation and Geoinformation**, v. 131, p. 103972, 2024.

GONZATTO JUNIOR, O. A.; NASCIMENTO, D. C.; RUSSO, C. M.; HENRIQUES, M. J.; TOMAZELLA, C. P.; SANTOS, M. O.; NEVES, D.; ASSAD, D.; GUERRA, R.; BERTAZO, E. K. et al. Safety-Stock: Predicting the demand for supplies in Brazilian hospitals during the COVID-19 pandemic. **Knowledge-Based Systems**, v. 247, p. 108753, 2022.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. **Advances in neural information processing systems**, v. 30, 2017.

Referências:



NUPPONEN, I. Predicting sales success with machine learning models. 2024. Master of Science in Economics and Business Administration Thesis – Aalto University School of Business.

SUJATHA, K.; ALEKHYA, Y. A Machine Learning Approach to Predict Drug Stock Based on Consumption Patterns for Dispensary Management System. *International Journal of Early Childhood Special Education*, v. 14, n. 5, 2022.

WANG, M.; LI, Y.; YUAN, H.; ZHOU, S.; WANG, Y.; IKRAM, R. M. A.; LI, J. An XGBoost-SHAP approach to quantifying morphological impact on urban flooding susceptibility. *Ecological Indicators*, v. 156, p. 111137, 2023.

ZHANG, T.; TANG, F.; HU, Y.; ZHANG, L.; GUO, Y. Shaping greener mobility: Impact of urban greening structure on time-dependent bike-sharing usage. *Transportation Research Part D: Transport and Environment*, v. 141, p. 104657, 2025.

ZHOU, S.; LIU, Z.; WANG, M.; GAN, W.; ZHAO, Z.; WU, Z. Impacts of building configurations on urban stormwater management at a block scale using XGBoost. *Sustainable Cities and Society*, v. 87, p. 104235, 2022.

2025



Obrigado!

Grupo 1B

Projeto

